Bakalářská práce

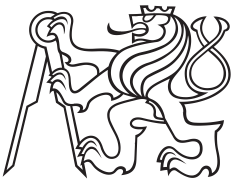

České
vysoké
učení technické
v Praze

F3

Fakulta elektrotechnická
Katedra kybernetiky

Detekce objektů z hloubkové kamery

Lukáš Kunt

Vedoucí: RNDr. Petr Štěpán, Ph.D.
Studijní program: Kybernetika a robotika
Květen 2020

Poděkování

Prohlášení

Abstrakt

Klíčová slova: slovo, klíč

Vedoucí: RNDr. Petr Štěpán, Ph.D.
Ústav X,
Uliční 5,
Praha 99

Abstract

Keywords: word, key

Title translation: Object Detection from Depth camera — Journey to the who-knows-what wondeland

Obsah

Obrázky

Tabulky

Kapitola 1

Matematický aparát

1.1 Homogenní souřadnice

Během celé práce budu pracovat jak s kartézskými, tak i s homogenními souřadnicemi. Ty jsou v Euklidovském prostoru dimenze n reprezentovány pomocí vektoru, který má $n+1$ prvků. Je-li $\boldsymbol{r}$ bod v trojdimenzionálním Euklidovském prostoru $\mathbb{E}^3$ reprezentován parametry x, y, z, pak pro převod mezi kartézskými a homogenními souřadnicemi platí následující vztahy.

$$\mathbf{r} = \begin{bmatrix} x \\ y \\ z \end{bmatrix} \rightarrow \mathbf{r}_{hom} = \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} \tag{1.1}$$

$$\mathbf{r}_{hom} = \begin{bmatrix} x \\ y \\ z \\ w \end{bmatrix} \rightarrow \mathbf{r} = \begin{bmatrix} x/w \\ y/w \\ z/w \end{bmatrix} \tag{1.2}$$

Pomocích homogenních souřadnic můžeme sestavit transformační matici $\mathbf{A}$, tato se skládá z matice rotace $\mathbf{R}$ a vektoru translace $\mathbf{t}$.

$$\mathbf{A} = \begin{bmatrix} \mathbf{R} & \mathbf{t} \\ \mathbf{0} & 1 \end{bmatrix} \tag{1.3}$$

1.2 Rotace a rotační matice

Natočení souřadného systému, popřípadě objektu s tímto svázaným vhledem k jinému systému v prostoru dimenze n se nejjednodušeji popíše pomocí rotační matice $\mathbf{R} \in \mathbb{R}^n$. Mezi nejběžnější rotační matice patří rotace o úhel θ kolem

os kartézského souřadného systému v $\mathbb{E}^3$. Tyto matice vypadají následovně.

$$\mathbf{R_x} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{1.4}$$

$$\mathbf{R_y} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{1.5}$$

$$\mathbf{R_z} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix} \tag{1.6}$$

Obecné natočení pak můžeme dostat složením 3 a více těchto rotací [1] Pro vytvoření matice rotace $\mathbf{R}$ v prostoru $\mathbb{R}^3$ kolem obecné osy dané normalizovaným vektorem $\mathbf{u}$ o úhel θ slouží Rodriguesův vzorec [21].

$$\mathbf{R} = \mathbf{I} + \tilde{\mathbf{u}}\sin\theta + \tilde{\mathbf{u}}^2(1-\cos\theta); \quad \tilde{\mathbf{u}} = \begin{bmatrix} 0 & -u_z & u_y \\ u_z & 0 & -u_x \\ -u_y & u_x & 0 \end{bmatrix} \tag{1.7}$$

Chceme-li natočit vektor $\mathbf{a}$ tak, aby byl rovnoběžný s vektorem $\mathbf{b}$, použijeme vzorec 1.7, úhel rotace θ a vektor $\tilde{\mathbf{u}}$, kolem kterého rotace proběhne, se určí následovně.

$$\tilde{\mathbf{u}} = \frac{\mathbf{a}\times\mathbf{b}}{\|\mathbf{a}\times\mathbf{b}\|} \tag{1.8}$$

$$\theta = \arccos\left(\frac{\mathbf{a}\cdot\mathbf{b}}{\|\mathbf{a}\|\,\|\mathbf{b}\|}\right) \tag{1.9}$$

Podle [10] je tato metoda nevhodná pro výpočet na počítači. Zejména pak v případech, kdy bychom měli počícat arccos hodnot blízko ± 1. Toto je způsobeno omezenou přesností reprezentace desetinných čísel v počítači (takzvaná floating point aritmetika). Přesnější je tedy použít tento vzorec.

$$\theta = \operatorname{atan2}\left(\|\mathbf{a}\times\mathbf{b}\|, \mathbf{a}\cdot\mathbf{b}\right) \tag{1.10}$$

Výhoda funkce atan2 oproti arcus tangens je ošetřené dělení nulou, ke kterému může dojít při zaokrouhlování desetinných čísel. Navíc funkce vrací úhel v rozmezí $[0, 2\pi]$

1.3 Sobelův operátor pro detekci hran

Hrana v obrazu může být také pozorována jako prudká změna intenzity obrazu v daném místě. Rychlé změny se dají detekovat pomocí gradientu, který je pro spojitou funcki $f(x,y)$ v bodě (x,y) vyjádřen následovně.

$$\nabla f(x,y) = \begin{bmatrix} \mathbf{G}_x & \mathbf{G}_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{bmatrix} \tag{1.11}$$

[1] Na pořadí zde záleží. Není možné dostat libovolnou rotační matici, pokud budou dvě po sobě doucí rotace probíhat kolem stejné osy

Velikost a směr gradientu se určí následovně.

$$\text{mag}(\nabla f) = ||\nabla f||_2 = \sqrt[2]{\mathbf{G}_x^2 + \mathbf{G}_y^2} \tag{1.12}$$

$$\boldsymbol{\theta} = \arctan(\frac{\mathbf{G}_y}{\mathbf{G}_x}) \tag{1.13}$$

Parciální derivace musí být spočítané pro každý pixel (x, y) obrazu $\mathbf{A}$. K tomuto se využívá Sobelových kernelů $\mathbf{K}_x$, $\mathbf{K}_y$. Tyto se konvolvují s obrazem a v každém bodě aproximují hodnotu obou parciálních derivací $g_x(x, y), g_y(x, y)$, ze kterých se pak podle vztahu 1.11 určí gradient.

$$\mathbf{K}_x = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & -1 \end{bmatrix} \quad \mathbf{K}_y = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{bmatrix} \tag{1.14}$$

$$g_x(x, y) = \sum_{k=-1}^{1} \sum_{l=-1}^{1} \mathbf{K}_x(k, l)\mathbf{A}(x + k, y + l) \tag{1.15}$$

$$g_y(x, y) = \sum_{k=-1}^{1} \sum_{l=-1}^{1} \mathbf{K}_y(k, l)\mathbf{A}(x + k, y + l) \tag{1.16}$$

$$\tag{1.17}$$

Určení gradientu intenzity tímto způsobem je relativně nenáročné. Pro zrychlení výpočtu se používá aproximace magnitudy gradientu místo exaktního výpočtu 1.12. Nejjednodušší aproximací je

$$\text{mag}(\nabla f) \approx ||\nabla f||_1 = |\mathbf{G}_x| + |\mathbf{G}_y|. \tag{1.18}$$

Ta dává sice velice nepřesný výsledek, ale pro aplikace, kde stačí hrubý odhad velikosti gradientu, může značně snížit výpočetní dobu.

1.4 Hledání konvexního obalu množiny bodů

Je-li dána množina S obsahující n bodů v euklidovském prostoru $\mathbb{E}^3$, popřípadě euklidovské ploše $\mathbb{E}^2$, pak konvexní obal H množiny S je nejmenší konvexní možina obsahující množinu S [7].

Mezi nejpoužívanější algoritmy pro hledání konvexního obalu bodů v euklidovské ploše $\mathbb{E}^2$ patří následující.

1.4.1 Grahamův algoritmus

Je nalezen bod $\mathbf{p}_0$, jehož y-ová souřadnice nabývá nejmenší hodnoty ze všech bodů množiny S. Všechny ostatní body jsou seřazeny podle úhlu, který svírají s osou x. K tomuto se využívá obecného třídícího algoritmu, jako je například heapsort, a tento krok má tedy časovou náročnost $\mathcal{O}(n \log n)$. Seřazené body jsou postupně procházeny a na základě následujícího kritéria

zařazeny[2], popřípadě vyloučeny z konvexního obalu H [15]

$$O(\mathbf{p},\mathbf{r},\mathbf{q}) = \det\begin{pmatrix} p_x & r_x & q_x \\ p_y & r_y & q_y \\ 1 & 1 & 1 \end{pmatrix} \qquad (1.19)$$
$$\left.\begin{matrix} \mathbf{r} \in H, \mathbf{p} = \mathbf{r}, \mathbf{r} = \mathbf{q}, \mathbf{q} = \mathbf{p_i} \text{ iff } O > 0 \\ \mathbf{r} \notin H, \mathbf{p} = \mathbf{p}, \mathbf{r} = \mathbf{q}, \mathbf{q} = \mathbf{p_i} \text{ iff } O \leq 0 \end{matrix}\right\},$$

kde $\mathbf{p}_i$ je další bod v pořadí seřazených bodů z S. Výše popsané ověřování bodů je provedeno v čase $\mathcal{O}(n)$.

Na podobném principu funguje i Andrewův algoritmus. Ten využívá lexikografického uspořádání bodů podle x-ové souřadnice, čímž se vyhne výpočtům s destinou čárkou, které mohou být zdrojem nepřesností.[6]

1.4.2 Jarvisův pochod (Jarvis march)

Je zvolen bod $\mathbf{p}_0$ náležící konvexnímu obalu H, což je například první bod v lexikografickém uspořádání bodů S. Ten je najit v čase $\mathcal{O}(n)$. Dále je spočítán relativní úhel mezi $\mathbf{p}_0$ a ostatními body. Z těch je pak vybrán bod $\mathbf{p}_n$, jehož úhel nabývá nejmenší hodnoty. Bod $\mathbf{p}_n$ je přídán do obalu H a postup se opakuje z bodu $\mathbf{p}_n$. Algoritmus končí ve chvíli, kdy platí $\mathbf{p}_n = \mathbf{p}_0$. Tento postup odpovídá postupnému procházení všech vrcholů polygonu, který reprezentuje konvexní obal, a jeho časová náročnost je $\mathcal{O}(hn)$, kde h je počet vrcholů. Může tedy být pro aplikace s předem známým počtem vrcholů rychlejší než Grahamův algoritmus.

1.4.3 Chanův algoritmus

Jedná se o ideální na výstup citlivý algoritmus určený k výpočtu komplexního obalu množiny. Výpočet dosahuje náročnosti $\mathcal{O}(n \log h)$

Množina bodů S je rozdělena do K množin Q_i. V každé množině se nachází maximálně m bodů, kde m je předem určená hodnota, pro kterou musí platit $m \geq h$. Pokud tato rovnost není splněna, musí být hodnota m zvýšena a algoritmus se opakuje. Následně je proveden Grahamův algoritmus na každou množinu Q_i s časovou náročností $\mathcal{O}(n \log m)$. Poté je zvolen bod, který náleží H a je užit Jarvisův pochod. Ten musí najít nejmenší prvek mezi maximálně m seřazenými vrcholy v K množinách, což je realizovatelné v čase $\mathcal{O}(K \log m)$. Pro h vrcholů je tedy výsledná časová náročnost $\mathcal{O}(n \log h)$, za předpokladu, že hodnota m je blízká hodnotě h.[7]

1.5 Nejmenší ohraničující obdélník

Nejmenší ohraničující obdélník je možné určit z konvexního obalu H množiny S. Ten může být najit v čase $\mathcal{O}(h)$ například pomocí star algoritmu [18] nebo pomocí otáčejících třemenů (rotating calipers).

[2] Bod zařezený do konvexního obalu může být v dalším kroku vyloučen.

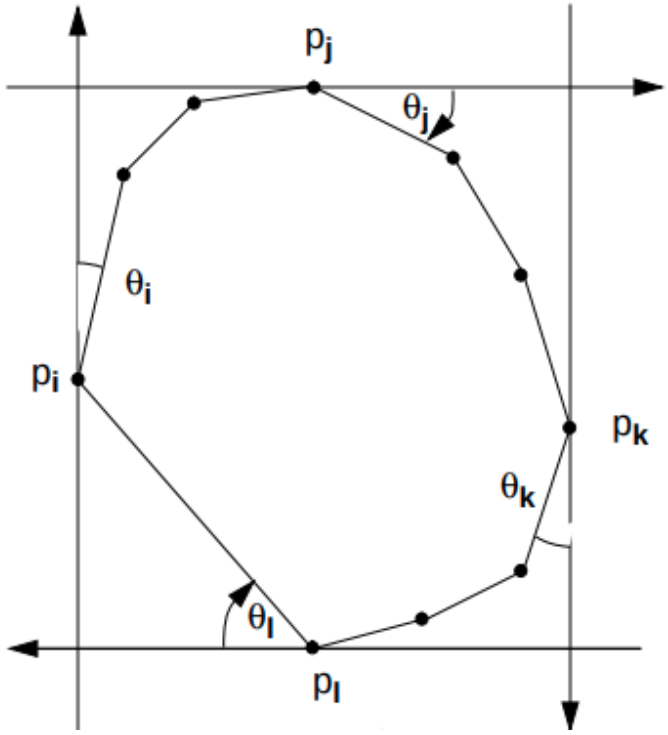

Obrázek 1.1: Otáčející se třmeny

Kolem množiny jsou umístěny dva páry na sebe ortogonální přímek, takzvaných třmenů (viz. obrázek 1.1), které se konvexního obalu dotýkají v některém z vrcholů $\mathbf{p}_i$, nebo mají společnou přímku spojující vrcholy $\mathbf{p}_{i-1}$ a $\mathbf{p}_i$. V každém kroku je spočítán úhel θ_i mezi třmenem, který se dotýká vrcholu $\mathbf{p}_i$, a vrcholem $\mathbf{p}_{i+1}$. Tento výpočet se opakuje pro všechny 4 třmeny, viz. obrázek 1.1. Následně je výbrán úhel $\theta = \min\{\theta_i, \theta_j, \theta_k, \theta_l\}$, o který je provedena rotace všech třmenů. Třmeny jsou pak ve směru svého normálového vektoru posunty tak, aby platila výše uvedená podmínka doteku třmenu s konvexní množinou v jednom, resp. dvou vrcholech. Dále je vypočten obsah obdélníku, jehož strany tvoří výše zmíněné třmeny. Celý postup se poté opakuje, dokud není vyzkoušeno všech h obdélníků. Následně je vybrán ten s nejmenší plochou.

1.6 Matematická morfologie

Popsání základních morfologických operací jako je dilatece, eroze, ...

1.7 RANSAC

popsání funkce ransac algoritmu

1.8 Vlastní čísla a vektory

Pro čtvercovou matici $\mathbb{A} \in \mathbb{R}^{n \times n}$ a nenulový vektor $\mathbf{v} \in \mathbb{R}^n$ a sklár $\lambda \in \mathbb{R}$ platí

$$\mathbf{A}\mathbf{v} = \lambda\mathbf{v}. \tag{1.20}$$

Skalár λ se nazývá vlastní číslo matice $\mathbf{A}$ a vektor $\mathbf{v}$ vlastní vektor příslušný vlastnímu číslu λ. Spektrální věta (viz. [22]) říka: Je-li matice $\mathbf{A}$ symetrická, pak má n vlastních čísel, kde $n = \text{rank}\mathbf{A}$ a všechna vlastní čísla jsou reálná.

Bude upraveno podle toho, co bude potřeba na popsání funkce PCA, SVD a ortogonální projekce

1.9 Singulární rozklad

Stručně posat singulární rozklad PCA a ortogonální projekci na podprostor

Singulární SVD[3]rozklad umožní každou matici $\mathbf{A} \in \mathbb{R}^{m \times n}$ rozložit jako

$$\mathbf{A} = \mathbf{U}\mathbf{S}\mathbf{V}^T \tag{1.21}$$

kde matice $\mathbf{S}$ je diagonální, matice $\mathbf{U}$ je ortogonální a obsahje vlastní vektory matice $\mathbf{A}\mathbf{A}^T$, obdobně je pak i matice $\mathbf{V}$ ortogonální a je složena z vlastních vektorů matice $\mathbf{A}^T\mathbf{A}$

1.10 Ortogonální projekce na podprostor

1.11 Analýza hlavních komponent

[3] Z anglického Singular Value Decomposition

Kapitola 2

Kamera

2.1 Dírkový model kamery

Kamera zobrazuje body euklidovského prostoru $\mathbb{E}^3$, které jsou popsány pomocí světových souřadnic na body v euklidovské ploše $\mathbb{E}^2$, která se nazývá obraz. Body obrazu se označují jako pixely.

Nejjednodušším modelem kamery je model dírkový, který má optické centrum, neboli centrum projekce, v konečnu. Centrum projekce umístíme do počátku kartézského souřadného systému a budeme uvažovat plochu kolmou na osu Z našeho souřadného systému, kterou nazveme obrazovou rovinou. Ta je popsána jediným parametrem a to ohniskovou vzdáleností f. V dírkovém modelu kamery se bod v prostoru $\mathbf{p} = (x, y, z)^T$ promítne na bod obrazu pomocí zobrazení

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} \mapsto \begin{bmatrix} fx/z \\ fx/z \end{bmatrix}, \tag{2.1}$$

což odpovídá bodu, kde přímka spojující centrum projekce a bod v prostoru, protne obrazovou rovinu (viz obrázek 2.1). Ve vztahu 2.1 jsme předpokládali, že počátek souřadného systému obrazu je v optickém středu. Konvencí však je za počátek souřadnic zvolit levý horní roh obrazu. K zápisu využijeme homogenních souřadnic a dostaneme následující rovnici

$$\begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix} \mapsto \begin{bmatrix} fx + zc_x \\ fy + zc_y \\ z \end{bmatrix} = \begin{bmatrix} f & 0 & c_x & 0 \\ 0 & f & c_y & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \\ 1 \end{bmatrix}, \tag{2.2}$$

pro zobrazení z souřadného systému kamery do systému obrazu s počátkem v levém horním rohu obrazu

kde jsme jako c_x a c_y označili souřadnice optického středu. Označíme-li obecný bod v prostoru, který je popsán v souřadném systému kamer, $\mathbf{x}_p$ a odpovídající bod v rovině obrazu $\mathbf{x}$, pak můžeme rovnici 2.2 přepsat jako

$$\mathbf{x} = \mathbf{K}[\mathbf{I} \mid 0]\mathbf{x}_p \quad \mathbf{K} = \begin{bmatrix} f & 0 & c_x \\ 0 & f & c_y \\ 0 & 0 & 1 \end{bmatrix}. \tag{2.3}$$

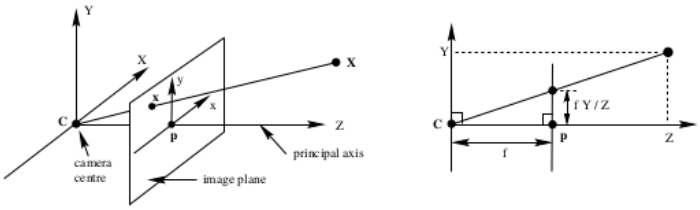

Obrázek 2.1: Model dírkové kamery

Matice $\mathbf{K}$ se nazýva matice vnitřních parametrů kamery.

Obecně je bod $\mathbf{x}$ v euklidovském prostoru popsán v jiném souřadném systému, než je ten se kterým je svázána kamera. Tento souřadný systém se nejčastěji nazývá světový. Přechod do souřadného systému kamery ze světového je možno popsat následovně

$$\mathbf{x}_p = \begin{bmatrix} \mathbf{R} & -\mathbf{R}\tilde{\mathbf{C}} \\ 0 & 1 \end{bmatrix} \mathbf{x}. \tag{2.4}$$

Jako $\tilde{\mathbf{C}}$ jsme označili počátek souřadného systému kamery vyjádřený v světových souřadnicích a $\mathbf{R}$ rotaci světového souřadného systému vzhledem ke kameře. Dosadíme-li nyní rovnici 2.3 do 2.4 dostaneme vztah popisující transformaci bodu z světových souřadnic do souřadnic obrazu

$$\mathbf{x} = \mathbf{K}\mathbf{R}[\mathbf{I} \mid -\tilde{\mathbf{C}}]\mathbf{x}. \tag{2.5}$$

Parametry $\tilde{\mathbf{C}}$ a $\mathbf{R}$ se souhrně nazývají vnější parametry kamery.

2.2 Stereo kamera

2.2.1 Výpočet vzdálenosti

Stereo kamera je tvořena dvěmi nezávislými čočkami. Zpracováním obrazů z obou čoček jsme schopni získat informace o hloubce každého pixelu. Budeme uvažovat model stereo kamery, kde jsou osy obou čoček rovnoběžné (viz obrázek 2.2). Osy jsou od sebe ve vzdálenosti b. Tomuto parametru se říka báze (baseline). Z podobnosti trojúhelníků plyne

$$\frac{z}{f} = \frac{x}{xl} \tag{2.6}$$

$$\frac{z}{f} = \frac{x-b}{xr}. \tag{2.7}$$

Pokud z rovnice 2.6 vyjádříme x a dosadíme do rovnice 2.7, pak po úpravě dostaneme výsledný vztah pro vzdálenost bodu od kamery

$$z = \frac{fb}{xl - xr} = \frac{fb}{d}. \tag{2.8}$$

Hodnota d se nazývá rozdíl (disparity) a xl, xr jsou souřadnice bodu $\mathbf{p}$ v levém, resp. pravém obrazu stereokamery. Pro každý bod v levém obrazu je tedy potřeba najít odpovídající bod v obrazu pravém (tzv. stereo pár). Bez jakékoliv apriorní znalosti by to znamenalo pro každý pixel prohledat celý druhý obraz, tedy náročnost hledání $\mathcal{O}(n^2)$. Pomocí epipolární geometrie můžeme hledání zúžit na přímku a snížit tak náročnost hledání stereo páru na $\mathcal{O}(n)$. [5]

2.2.2 Chyba výpočtu vzdálenosti

Chyba výpočtu vzdálenosti se určí derivací rovnice 2.8 podle d [12]

$$\frac{\partial z}{\partial d} = \frac{z}{fb} \tag{2.9}$$

$$|\epsilon_z| = \frac{z^2}{fb}|\epsilon_d|, \tag{2.10}$$

kde ϵ_z je chyba určení vzdálenosti bodu a ϵ_d je chyba rozdílu. toto je vlastnost kamery, popřípadě algoritmu použitého ke hledání odpovídajících párů, a nabývá téměř konstantních hodnot [12]. Z rovnice 2.10 tedy plyne, že chyba je úměrná kvadrátu vzdálenosti daného bodu a přesnost stereo kamer se vzdáleností rychle klesá.

2.2.3 Epipolární geometrie

Epipolární geometrie se zabývá průnikem obrazových rovin se svazkem ploch, jejichž společná osa je báze. Uvažujme dvě dírkové kamery v obecném natočení, tedy jejich obrazové roviny nemusí být rovnoběžné, viz 2.3. Z dírkového modelu kamery plyne, že bod $\mathbf{X}$, který se nachází v euklidovském prostoru, a optické středy kamer C, C' jsou koplanární a tvoří rovinu p. V místě, kde tato rovina protíná roviny obrazu, se nachází epipolární přímky . Hledáme-li stereo pár, pak pro známý bod $\mathbf{x}$ (tj. projekce bodu $\mathbf{X}$ do optické roviny levé kamery) musíme najít odpovídající bod $\mathbf{x}'$. Ten může ležet pouze na epipolární přímce l', která je jednoznačně určena epipólem e' a bodem x'. Epipól se nachází v místě, kde přímka spojující optická centra kamer protíná rovinu obrazu. Pro bod $\mathbf{x}'$ platí

l a l' bold or normal text

$$\mathbf{x}' = \mathbf{H}\mathbf{x}, \tag{2.11}$$

kde $\mathbf{H}$ je homografie mezi rovinami obrazu. Toto zobrazení je ovlivněno pouze vzájemnou polohou kamer a jejich vnitřními parametry. Nezávisí tedy na scéně. Z bodu $\mathbf{x}'$ se pak již lze určit epipolární přímku

$$\mathbf{l}' = \mathbf{e}' \times \mathbf{x}' \tag{2.12}$$

$$\mathbf{l}' = \mathbf{e}' \times \mathbf{H}\mathbf{x} \tag{2.13}$$

$$\mathbf{l}' = \mathbf{F}\mathbf{x}. \tag{2.14}$$

Matice $\mathbf{F}$ se nazývá fundamentální a představuje zobrazení $f : \mathbb{R}^3 \mapsto \mathbb{R}^3$. Jelikož však platí $\text{rank}F = 2$, pak $\dim(\ker F) = 1$ Pokud jsou obě optické

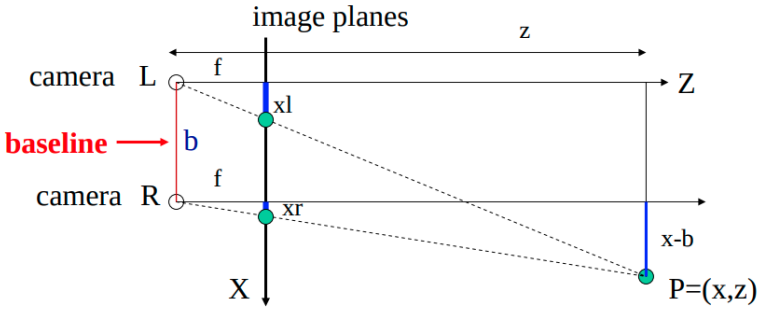

Obrázek 2.2: [2]

osy stereo kamery rovnoběžné, pak se výpočet epipolární přímky velice zjednodušší, jelikož homografie mezi rovinami obrazu je pouze posunem ve směru báze.

2.3 Hledání stereo páru

Metody užívané pro hledání stereo páru se dělí na metody plošné (area based) a metody založené na porovnávání rysů (features). Při hledání stereo páru se často využívá následujících omezení, která tento proces zjednodušší. Tato omezení však v extrémních případech, jako je například okluze, nemusí platit.

- Epipolární omezení: Pixel v druhém obrazu se nachází (pokud existuje) na epipolární přímce ,viz. sekce 2.2.3.
- Spojitost: Rozdílová, popř. hloubková, mapa by měla být po částech spojitá.
- Jedinečnost: Každý pixel v levém obrazu má k sobě právě jeden odpovídající v obrazu pravém.
- Pořadí: Pořadí pixelů v levém obrazu odpovídá pořadí v pravém.

2.3.1 Plošné metody

Využívají informaci z okolí pixelu. Ty jsou porovnány se všemi přípustnými pozicemi v druhém obrazu a bod, jehož hodnota je nejblíže vzoru, tvoří stereo pár. Mezi nejpoužívanější variace plošných metod patří následující.

Součet absolutních rozdílů

Je definována konstatní velikost okolí pixelu $\mathbf{x}(u, v)$. Následně jsou hodnoty všech pixelů v okně sečteny a výsledná hodnota je provnána s body v pravém obrazu, kde se může korespondující pixel nacházet, tj. body které splnují

námi používaná omezení. Pro odpovídající bod $\mathbf{x}'$ tedy platí

$$\mathbf{x}' = \text{argmin} \left(\sum_i \sum_j |\mathbf{I}_l(u+i, v+j) - \mathbf{I}_r(u+i, v+j+d)| \right), \qquad (2.15)$$

kde $\mathbf{I}(u, v)$ je intenzita příslušného pixelu, d je posun okna ve druhém obrazu a součet probíha přes celé okno. Vztah byl zjednodušen uvažováním horizontálních epipolárních přímek. Toto odpovídá konfiguraci kamery s rovnoběžnými optickými osami.

Existuje mnoho podobných algoritmů, které se liší pouze metrickou funkcí. Místo absolutní hodnoty rozdílu je užit například kvadrát rozdílu nebo jeho normalizovaný kvadrát. Jedná se o nejrychlejší algoritmy pro hledání stereo páru, přesto však dosahují vysokých přesností [13].

Cenzus

Jedná se o variaci algoritmu patřící do rodiny plošných metod, které před porovnáním hodnot pixelů provedou určitou transformaci obou obrazů. Patří sem naříklad i transformace podle hodnoty (rank transform). Cenzus opět pracuje se definovanou maskou kolem pixelu, pro který hledá stero pár. Pixely, které se nachází v šabloně, se transformují na vektor jedniček a nul podle toho, zda je hodnota intenzity pixelů masky větší, popřípadě menší, než intenzita centrálního pixelu. Stejná transformace se provede i v pravém obrazu pro každý pixel, který může doplnit stereo pár. Vektory jsou následně porovnány a je vybrán ten, jehož vektor má nejmenší Hammingovu vzdálenost. [13, 5]

2.3.2 Porovnávání rysů

Pro každý obraz jsou vygenerovány důležité body. To mohou být například hrany či rohy v obrazu. Tyto rysy jsou porovnány s analogicky vygenerovánými rysy v druhém obrazu. Tento postup se v některých aplikacích opakuje, přičemž v každém dalším kroku je každý rys rozložen na několik menších, o kterých již máme apriorní znalost jejich přibližné polohy. Aby bylo možné sestavit obraz pouze z několika rysů, je nutné provést časově náročné předzpracování obrazu za účelem najití vhodných rysů a po nalezení korespondujících rysů provést zpětnou rekonstrukci obrazu. [5]

Pro porovnání rysů mezi levým a pravým obrazem se využívá algoritmů jako je například SIFT (Scale Invariant Feature Transform), SURF (Seeded-Up Robust Features) nebo BRIEF(Binary Robust Independent Elementary Features).

2.4 Intel Realsense D435

Intel® Realsense™ D435 je širokoúhlá stereo kamera, která se skládá z RGB kamery, infračerveného projektoru a dvou infračervených kamer, jejichž data jsou zpracovává přímo v čipu kamery dedikovaným procesorem. Výstupem z

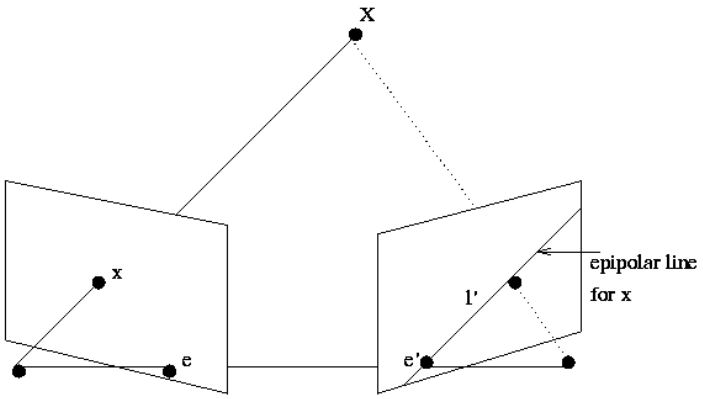

Obrázek 2.3: Placeholder

Obrázek 2.4: Fotografie kamery Intel® Realsense™ D435 [1]

kamery je tedy barevný obraz (RGB) a vzdálenost jednotlivých pixelů neboli hloubková mapa.

Dvě infračervené kamery jsou v konfiguraci s rovnoběžnými optickými osami ve vzdálenosti 50 mm. Infračervený projektor promítá na scénu statický obrazec, který se nachází mimo viditelné spektrum a není tedy zachycen RGB kamerou. Tento obrazec slouží k najití stereo párů, zejména pak u objektů s řídkou texturou.

Kamera je vybavena specializovaným procsorem Vision Processor D4 pro výpočet hloubkové mapy. Ten je schopen při rozlišení hloubkové kamery 848x480 zpracovávat až 90 snímků za sekundu (FPS). Při této rychlosti snímání je přesnost kamery výrazně snížena [12]. Pro maximální přesnost je vhodné nastavit frekvenci na 30 snímků za sekundu.

Procesor má stejně jako celá kamera velice nízký odběr elektrické energie. Celá kamera včetně IR projektoru má odběr menší než jeden watt a je tedy vhodná pro mobilní aplikace, kde je velikost baterie a spotřeba energie omezujícím faktorem. [3]

Porovnání s Kinectem a Asus RGBD kamerou

Pro hledání stereo párů je využit algoritmus cenzu popsaný v 2.3.1 s maskou o velikosti 7×7. Výsledky jsou následně ověřovány sadou filtrů, které měří důvěryhodnost shody. Podle nastaveného limitu důležitosti pak pro tento pixel buď vygenerují záznam v hloubkové mapě, nebo pixel zůstane nevyplněn. Výsledky kamery pro různé hodnoty limitu jsou vidět v tabulce 2.5.

Procesor kamery není schopen určit hloubku bodů, pokud se objekt nachází příliš blízko. Konkrétní hodnoty je možno vidět v tabulce 2.6. Maximální

Preset	FPR	$r_{\rho=95\%}$	$\max(\sigma_x, \sigma_y) > \sigma_z$
Off	91.3%	7.0 m	6.1 m
Low	19.8%	6.9 m	6.6 m
Medium	5.8%	5.8 m	6.7 m
High	0.5%	4.2 m	6.8 m

Obrázek 2.5: Postupně zleva: Hodnota limitu, počet falešných shod pokud je scéna blíže než je minimální vzdálenost detekce kamerou. Vzdálenost, kdy vyplněnost hloubkové mapy klesne pod 95%, a vzdálenost při které je směrodatná odchylka ve směru osy z menší než ve směru x a y [12]

Resolution	D400/D410/D415	D420/D430
	Min-Z (mm)	Min-Z (mm)
1280x720	450	280
848X480	310	195
640x480	310	175
640x360	240	150
480x270	180	120
424x240	160	105

Obrázek 2.6: Tabulka minimální detekovatelné hloubky [3]

měřitelná vzdálenost je za ideálních podmínek až 40 metrů [12]. S rostoucí vzdáleností se kamera chová podle rovnice 2.10 a přesnost tedy rychle klesá. Toto chování neodpovídá rovnici 2.10, pokud kamera operuje s objekty, které se nachází na obou hranicích měřitelné vzdálenosti. Ilustrace výstupu kamery, pokud se objekt nachází ve vzdálenosti meší než specifikuje tabulka 2.6 je vidět na obrázku 2.7b.

2.5 Metody v detekci objektů z hloubkových dat

Existuje spoustu různých metod pro detekci objektů z hloubkových dat. Ty se liší podle různorodosti detekovaných objektů, požadavků na čas výpočtu, možnosti získání trénovacích dat nebo formátem vstupních dat. Obvyklým formátem je mračno bodů, neboli point cloud, což je nestrukturovaná množina bodů v trojrozměrném prostoru. Zejména v posledních letech s nástupem hloubkových kamer jako je například Microsoft Kinect, Asus Xtion nebo námi používaný Intel RealSense, se čím dál více používají data ve formátu RGB-D obrazu. Ten se dá pomocí vztahu 2.2 převést na point cloud. Výstupní data z hloubkové kamery bývají většinou oproti LIDARu méně přesné. Výhodou naopak je vysoká vzorkovací frekvence, velké množství výstupních bodů a cena.

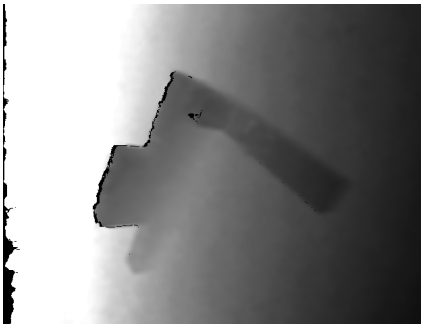

(a) : Snímek bez výrazných výpadků dat hloubkové mapy

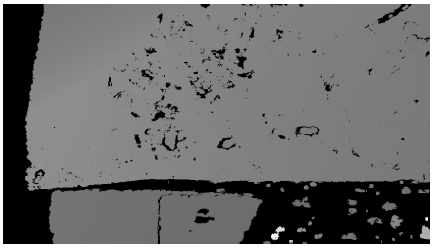

(b) : Snímek s chybějícími hloubkovými daty

Obrázek 2.7: Výstupní data kamery Realsense, hloubková data byla převedena do odstínů šedé

2.5.1 Klasické metody

Určení normálového vektoru plochy z nestrukturovaných dat

Téměř všehny metody detekce z objektů se skládájí z více kroků a jedním z nich většinou bývá určení normálového vektoru plochy. Obvykle se jedná o plochu reprezentující zem, popřípadě jinou podložku, nebo plochy reprezentující stěny místnosti. Přístupy k hledání ploch v obrazu se výrazně liší, uvedeme příklady některých z nich.

- Použití hrubé síly (brute force). Postupně jsou vyzkoušeny všechny možnosti, popřípadě část z nich, a vybere se nejlépe vyhovující. Využívá se zde zejména algoritmů jako je RANSAC, případně jeho modifikace. Tato metoda je vhodná zejména pokud jsou data zatížena silným šumem, jelikož při správném počtu iterací téměř vždy vrátí správný výsledek. Toto je však vykoupeno vysokou časovou náročností [8, 4], která se dá snížit vhodný předzpracováním dat, například segmentací na menší celky a určením plochy pouze pro tyto segmenty. [16]

- Výpočet normálového vektoru v každém bodě. Normálový vektor je kolmý na plochu reprezentující okolí bodu. Toto okolí je tvořeno body nacházejícími se v okruhu o poloměru r [20] ,popřípadě k nejbližšími body[9, 19]. Poté je provedena segmentace pomocí metody rostoucích oblastí viz. sekce 2.5.2. Výstupem jsou tedy skupiny bodů, které představují jednotlivé plochy. V některých případech je navíc použit RANSAC na již nalezené segmenty za účelem vyloučení bodů, které leží mimo plochu představovanou daným segmentem, přestože jejich normálový vektor dané ploše odpovídá [14].

- Jsou nalezeny body, které patří do dané roviny, a těmi je poté pomocí PCA proložena rovina [23]. Tato metoda vyžaduje přesné určení bodů, o kterých se předpokládá, že tvoří danou rovinu. Jediný bod ležící ve velké

vzdálenosti od roviny (outlier) může způsobit velké nepřesnosti, jelikož rovina je proložena body metodou nejměnších čtverců.

2.5.2 Segmentace obrazu

Důležitým krokem pro porozumění obrazu a detekci objektů je segmentace obrazu, tj. rozdělení vstupních dat na skupiny. Rozdělujeme dva typy segmentace. Sémantickou, která sjednocuje body reprezentující danou skupinu objektů (např. všechny bloky ležící na zemi), a segmentaci jednotlivých instancí, kdy je skupina objektů rozdělena na jednotlivé zástupce dané skupiny.

Přístup k segmentaci se liší podle dané aplikce. Nejpoužívanějšími metodami jsou tyto:

- Metoda prahování. Body $\mathbf{p}(x, y)$ jsou rozděleny do m skupin podle toho, zda jejich vlastnost V, což je například vzdálenost bodu od kamery nebo od plochy, dosahuje stanovené hodnoty T_m. Tato hodnota může být pevně určená, nebo se může dynamicky měnit, a to v závislosti na okolních bodech, nebo v závislosti na pozici v obrazu, tj. $T(x, y)$. Pro prahovací metodu tedy platí následující vztah

$$\left\{\begin{array}{l} \mathbf{p} \in m \text{ iff } V(\mathbf{p}) > T_m \\ \mathbf{p} \in n \text{ iff } V(\mathbf{p}) > T_n \\ \mathbf{p} \in \emptyset \text{ iff } V(\mathbf{p}) \leq T_1 \end{array}\right\}. \tag{2.16}$$

- Metoda detekce hran. V obrazu jsou detekovány prudké změny pozorované vlastnosti V v bodě $\mathbf{p}$ za pomoci první derivace vlastnosti V v bodě $\mathbf{p}$. Pokud hodnota derivace dosáhne daného prahu je $\mathbf{p}$ registrován jako hrana. Po výpočtu bývá provedena úprava těchto hran, kterou je například filtrování, popřípadě spojení některých sousedních bodů. Nakonec jsou v obrazu identifikovány segmenty bodů, které jsou od zbytku odděleny hranou. K určení hran se využívá například Sobelova operátoru, který byl popsán v sekci 1.3, nebo Cannyho operátoru.

- Metoda rostoucí oblasti. Ta se dělí na dva typy: S počátečním bodem (seed) a bez počátečního bodu.

  Je zvolen jeden, popřípadě několik počátečního bodů. K těmto se postupně přidávají sousední body, pokud splňují předem definované podmínky. Těmi jsou například maximální odchylka normálových vektorů bodů od normálového vektoru seedu, nebo rozdíl velikost některé souřadnice. Metoda bez počátečního bodu pak rozdělí všechny body do skupin, jejichž body spolu sousedí a zároveň mají podobné vlastnoti. Jedná se o algoritmus, který pracuje s konstatní časovou náročností odpovídající $\mathcal{O}(2n)$, kde n je počet pixelů obrazu.

- Metoda rozdělovaní a slučování. Obraz je postupně rozdělen na části, které mají podobnou charakteristiku. Následně jsou sousední regiony, které jsou si podobné, sloučeny do jedoho. Pro reprezentaci regionů se obvykle využívá kvadrantový strom (quadtree).

Nechť o je obraz a V daná vlastnost jednotlivého bodu $\mathbf{p}$. Skupina bodů má vlastnost V, pokud tuto vlastnost má každý bod skupiny. Metodu rozdělování a slučování lze za těchto podmínek popsat následovně.[11]

- Region R_1 je roven o.
- Pokud platí $V(R_i) = False$, pak je region rezdělen na několik menších.
- Pokud platí $V(R_i) = True$, pak je R_i sloučen se všemi sousedními regiony R_j, přičemž musí platit $V(R_i \cup R_j)$. Tento krok se opakuje, dokud je možné některý region sloučit.

- Metoda shlukování (clustering). Obraz je rozdělen do shluků, ve kterém má každý bod podobné vlastnosti, resp. jejich vlastnosti jsou si v rámci obrazu nejbližší. Vlastnost v tomto případě bývá nejčastěji euklidovská vzdálenost. Mezi nejpopulárnější algoritmy patří[1]

  - K-means algoritmus. V tomto algoritmu je předem nutné znát počet shluků m, do kterých budou body rozděleny. Následně se náhodně vybere m bodů, které představují střed shluku. Poté je pro každý bod spočítána vzdálenost od jednotlivých středů. Bod je přiřazen do daného shluku, jehož vzdálenost středu je nejmenší. Následuje přepočítaní středů a postup se opakuje. Ve chvíli kdy již nedochází ke změnám mezi jednotlivými shluky je zaznamenán součet rozptylů bodů v rámci jednotlivých shluků a celý proces počínaje náhodnou volbou středů se n-krát opakuje. Nakonec je vybrán výsledek, který má nejmenší rozptyl.
  - Mean-shift algoritmus. Je předem definován poloměr kruhového okna r. Následně je náhodně určeno (popřípadě podle předem definované masky rozmístěno) n bodů $\mathbf{p}$. V každé iteraci se spočítá střed bodů $\mathbf{t}$, pro které platí $||\mathbf{t} - \mathbf{p}|| < r$, ty naradí bod $\mathbf{p}$. Tento postup se opakuje, dokud body konvergují. Výsledná poloha bodů $\mathbf{p}_i$ pak představuje sřed jednotlivých shluků.
  - DBSCAN (Density-Based Spatial Clustering of Applications with Noise) algoritmus. Všechny body obrazu jsou označeny jako nenavštívené. Náhodně je vybrán nenavštívený bod $\mathbf{a}$ a pokud se v jeho okolí o velikosti ϵ nachází minimální předem zvolený počet bodů, je celé okolí bodu $\mathbf{p}$ přidáno do shluku a postup se opakuje pro přidané body. Pokud již nelze žadný další bod přidat zvolí se další nenavštívený bod a proces se opakuje pro další shluk. Toto probíhá dokud existují nenavštívené body.

[1] Princip algoritmů bude vysvětlen při shlukování podle euklidovské vzdálenosti

Detekce objektů

2.5.3 Metody na bázi neuronových sítí

Již daleko stručněji porovnat klasické metody s těmi, které využívají CNN. Popsat výhody a nevýhody oproti klasickým metodám

2.6 Navržené řešení

Navržené řešení se skládá ze 3 částí a to v souladu se sekcí 2.5, tedy nalezení normálového vektoru podložky, segmentace obrazu na jednotlivé cihly a následné nalezení ohraničujících boxů pro jednotlivé cihly. Pro všechny části řešení bylo navrhnuto více postupů a jejich výsledky jsou porovnány v sekci 2.8. Ve všech částech se vychází ze zadání, které specifikuje, že na zemi nemůže být kromě cihel žadný jiný objekt podobných rozměrů. Velikost cihel je předem známa, mimo jejich délky, která může nabývat různých rozměrů. Cihly na sebe mohou být naskládany v libovolném počtu vrstev, mohou se objevit v libovolném natočení a navzájem se dotýkat. dále platí, že pokud se nachází některá cihle v patře n, tak ve všech patrech $0, ..., n-1$ se pod touto cihlou také nachází cihly. To znemená, že pokud jsou cihly postaveny do zdi, pak tato zeď nemá díry.

V některých částech byl zaveden předpodklad doteku dvou cihel pouze po celé délce odpovídajících stěn za účelem rychlejší alternativy detekce.

2.6.1 Detekce normálového vektoru a sémantická segmentace obrazu

Přístup založený na výšce

Začneme určením normálového vektoru roviny reprezentující zem. Z jeho znalosti, můžeme odečtením plochy představující zem, najít body ležící nad zemí, tj. body představující cihly. Dostaneme tedy sémanticky segmentovaný obraz.

Vytvoříme mřížku bodů, které jsou v místech, kde předpokládáme přesný výstup kamery. U těch ověříme, zda pro ně byla kamerou vygenerována hloubka a zda bod leží v maximální vzdálenosti 4 m, jelikož podle [12] chyba stereo kamery RealSense D435 nad tuto vdálenost začíná být markantní a správné určení normálového vektoru je zásadní pro všechny ostatní kroky. Množinu bodů $M = \mathbf{a}_1 \dots \mathbf{a}_m$, které splňují výše uvedená kritéria, proložíme rovinou pomocí PCA algoritmu a dostaneme normálový vektor $\mathbf{n}$ plochy p minimalizující kvadrát vzdáleností od bodů. Tato plocha je posunuta mimo

počátek o d.

$$\bar{\mathbf{a}} = \frac{1}{m}(\mathbf{a}_1 \dots \mathbf{a}_m) \tag{2.17}$$

$$d = \mathbf{n} \cdot \bar{\mathbf{a}} = \mathbf{n}^T \bar{\mathbf{a}} \tag{2.18}$$

$$p : n_1 x + n_2 y + n_3 z - d = 0 \tag{2.19}$$

Každý bod $\mathbf{a}$ je buď součástí země, nebo součastí cihly. Je-li v množině M k bodů, které jsou součastí země G, pak zbylých $m - k$ bodů musí být součastí mračna bodů reprezentující cihlu C. Tyto body se vždy nachází ve výšce z [2]nad zemí a tedy pro každý bod $\mathbf{a}$ platí

$$n_1 a_1 + n_2 a_2 + n_3 a_3 + \epsilon > d \;\rightarrow\; \mathbf{a} \in C \tag{2.20}$$

$$n_1 a_1 + n_2 a_2 + n_3 a_3 + \epsilon \leq d \;\rightarrow\; \mathbf{a} \in G, \tag{2.21}$$

kde ϵ je experimentálně určená hodnota ošetřující případy, kde $k = m$, tj. všechny body reprezentují zem. V tomto případě čast bodů bude ležet nad plochou p. To jest dáno šumem dat a nepřesností kamery. Přidáním parametru ϵ je zajištěno, že každý bod reprezentující zem bude správně klasifikován i při zašuměných datech.

Po výběru bodů z mřížky podle výše uvedených kriterií dostaneme k bodů, které reprezentují zem a nacházejí se v místech, kde je přesnost kamery v rámci jejich možností nejvyšší. Tyto body by se daly znovu proložit plocho, čímž bychom dostali aproximaci natočení země pomocí normálového vektoru $\mathbf{n}$. Vzhledem k důležitosti přesnosti určení $\mathbf{n}$ získáme další body reprezentující zem pomocí algoritmu 1. Tyto body opět pomocí PCA proložíme rovinou a dostaneme přesnější aproximaci normálového vektoru země, viz. sekce 2.8. Na obrázku 2.8 lze pozorovat výsledek algoritmu 1.

musí být algoritmus v české jazyce? Zejména pak notoricky známé pojmy jako stack atd...

Nyní vypočítáme výšku každého bodu nad rovinou a podle této vzdálenosti přidělíme hodnotu 0 až k, kde číslo reprezentuje očekávaný počet na sobě naskládaných cihel a k maximální počet cihel, jež může být na sebe naskládán. Vizualizace tohoto výsledku je vidět na obrázku 2.9

Detekce normálového vektoru pomocí RANSAC

Body jsou postupně prokládány roviny pomicí RANSAC algoritmu, viz. 1.7. Zde je potřeba správně určit kritérium, při jehož splnění budeme mít jistotu, že dotekovaaná plocha představuje zem. Pokud by algoritmus skončil po detekci plochy, v jejimž okolí leží nejvíce bodů. Mohli bychom při velkém zastoupení kostek v obrazu dostat rovinu popisující horní stěnu těchto kostek. Jako terminační kritérium je tedy zvolena detekce dvou rovin a jejich následným porovnáním vybereme tu, která popisuje zemi.

[2]Osa z směřuje směrem z kamery a body nacházající se nad zemí mají tedy menší hodnotu z.

Algorithm 1 Expandování bodů

```
Stack ← ∅
G ← ∅
for a in M do
  Stack.push((a))
  z ← height of a
  while not Stack.empt() do
    t ← Stack.pop()
    G ← G ∪ t
    V ← V ∪ p
    for n in neighbours of t do
      zn ← height of n
      if zn ∈ [z − δ, z + δ] and not n ∈ G then
        stack.push(n)
      end if
    end for
  end while
end for
```

Přístup založený na změně výšky

Velice populární postup při segmentaci obrazu je založen na porovnání normálového vektoru v bodech obrazu. Normálový vektor je vypočten pro každý bod obrazu a následně jsou body, jejichž normálový vektor má podobný směr, popřípadě i velikost, sloučeny do větších celků. V našem případě je vrchní stěna cihly paralelní se zemí a má tedy stejný normálový vektor. Nachází se však v jiné výšce. Pomocí výpočtu gradientu, který budeme realizovat užitím Sobelova operátoru aplikovaného na výšku bodů, spočítáme derivaci výšky. Ta by měla být nejvyšší v oblasti přechodu země - cihla. Následně pak sloučíme body s hodnotou gradientu výšky, která se liší v rámci skupiny maximálně o δ. K tomu bylo využito upraveného CCL (Connected-component labeling) algoritmu.

Tato metoda při správném odladění parametru δ funguje velice přesně. Problémem je však robustnost. Hodnoty parametru δ fungující na cihly v blízkosti kamery nedetekují cihly ve vzdálenosti řadově $2\,m$ a více a naopak. Toto je způsobeno jednak šumem kamery, který podle rovnice 2.10 roste kvadraticky, a zejména pak zkreslením vzdálenější hrany cihly kamerou, viz. obrázek 2.10. Kamera zde špatně nachází stereo páry a generuje mračna bodů, která ve skutečnosti neexistují. Ty zmírňují přechod cihla-zem a snižují tak hodnotu gradientu. Toto chování je dobře vidět na obrázku 2.11.

2.6.2 Detekce objektů ze segmentovaného obrazu

Stejně jako při segmentaci obrazu, tak i zde bylo vyzkoušeno několik algoritmů. Některé z nich byly nastaveny na detekci za zjednodušujících podmínek a nabízí tak nižší výpočetní náročnost při stejné přesnosti detekce. Vstupem

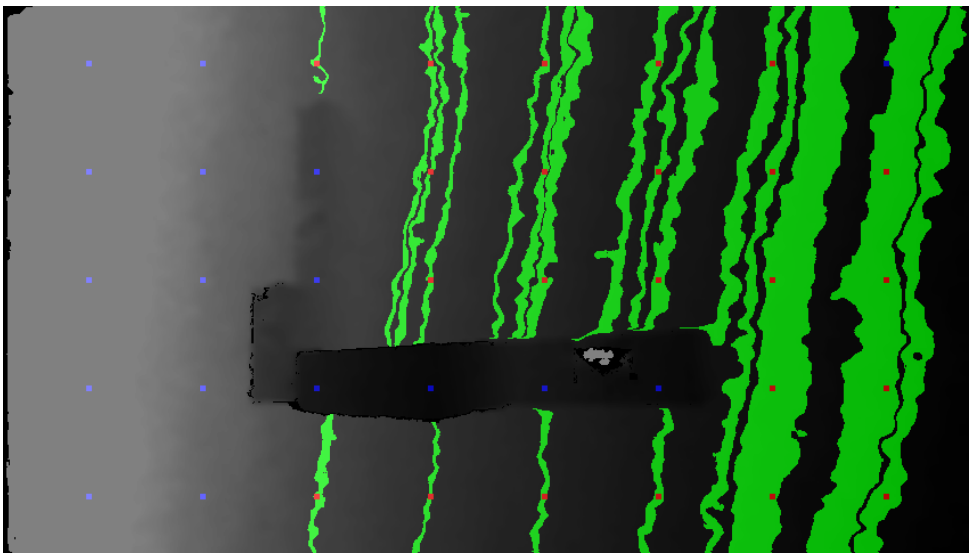

Obrázek 2.8: Červenou barvou jsou znázorněny body, ze kterých probíhal algoritmus 1, modré body byly podle výše uvedených kritérií vyřazeny a zeleně jsou znázorněny výsledné body reprezentující zem

všech prezentovaných algoritmů bude segmentovaný obraz jako je například obrázek 2.9. Tedy vstupem je presketivně deformovaný púdorys jednotlivých cihel.

Detekce pomocí nejmenší ohraničujícího obdélníku

V tomto algoritmu předpokládáme, že cihly se navzájem nedotýkají, popřípadě se dotýkají pouze po celé délce navzájem si odpovídajících stěn.

Nejprve je na obraz použita morfologická operace otevření, viz sekce 1.6. Pomocí této operace je obraz vyfiltrován a jsou odstraněny body představující šum. Následně jsou nelezeny obrysy shluků cihel[3] pomocí Suzukiho algoritmu [17], kde jsme využili již implementovaného programu v knihovně OpenCV.

Pomocí průměrového filtru jsou vyhlazena data reprezentujících obrys shluku cihel, resp. jejich výška. Poté je obrys aproximován konvexním obalem, čímž se zmenší počet bodů, kterými popisujeme daný shluk cihel. Tento shluk je deformován prespektivním zkrslením

Obraz horní stěny kvádr nepodléhá prespektivnímu zkreslení, je-li horní stěna kolmá na optickou osu kamery, tedy normálový vektor reprezentující horní stěnu kvádru musí být rovnoběžný s optickou osou kamery. Normálový vektor horní stěny kvádru ležícího na zemi je stejný s normálovým vektorem $\mathbf{n}$ země, který byl určen v sekci 2.6.1. Natočení země vůči kameře je vnější vnější parametr kamery. Body obrazu můžeme tedy transformovat do jejich projekce na rovinu země pomocí upraveného vzorce 2.5 jako

$$\mathbf{x} = \begin{bmatrix} \mathbf{I} \\ 0 \end{bmatrix} \mathbf{K}^{-1}\mathbf{R}^{-1}\mathbf{x}_p, \tag{2.22}$$

Bod $\mathbf{x}$ bude vyjádřen v homogenních souřadnicích a bude mít tedy tvar x,y,z,1 ...mohu rovnici dole zapsat takto? jedná se o korektní převedení rovnice 2.5, nebo musím explicitně vyjádřit $\mathbf{x}$?

[3] Shlukem cihel se myslí skupina cihel, které jsou spojeny dotekem

Obrázek 2.9: Vzdálenost boudů od roviny zobrazena jako počet na sobě lžících cihel

kde $\mathbf{R}$ je matice určená pomocí Rodriguezova vzorce 1.7. Úhel θ mezi optickou osou a normálovým vektorem byl určen pomocí vztahu 1.9 a vektor $\tilde{\mathbf{u}}$, kolem které rotace probíhá, pomocí vztahu 1.8. Dostaneme body, které představují konvexní obal, zbavené prespektivního zkrslení.

Následně je nalezen nejmenší obdélník, který opisuje tyto body, viz sekce 1.5. Obdélník je plně popsán svými rohy. Na tyto rohy aplikujeme transformaci 2.5 a dostaneme body v obrazu, které odpovídají ohraničujícímu obdélníku po aplikování prespektivního zkrslení.

Výše uvedený postup se je proveden pro každou skupinu kostek a následně pro každé patro. Hledáme-li projekci patra n, pak jsou z dat odstreněny body,které odpovídají patrům $0, ..., n-1$ a postup se opakuje od začátku pro všechny skupiny bloků. Výsledek algoritmu je vidět na obrázku 2.12

2.6.3 Detekce pomocí RANSAC

Postup popsaný v sekci 2.6.2 funguje pouze za zjednodušujících předpokladů a navíc jeho přesnost značně klesá při nesprávném generování stereo párů, jako je vidět na obrázku 2.10. Tato metoda funguje pro všechna natočení cihel a je i velice robustní.

Začneme obdobně jako v sekci 2.6.2 transformací bodů představující obrysy pomocí vztahu 2.22. Mezi body, představující prespektivně nezkreslený obrys, najdeme pomocí RANSAC přímku p_1. Ta odpovídá některé z delších stěn cihly. Následně je opět použit RANSAC a mezi zbylími body je nelezena přímka p_2 rovnoběžná s p_1. Tímto dostaneme obě protější stěny cihly. Hledání zbylých 2 kratších stěn je nerealizovatelné i pomocí RANSAC algoritmu, jelikož tyto stěny jsou daleko kratší a tedy reprezentovány méně body. Pokud je obraz zašuměn, pak není možné najít přímku odpovídající této stěně.

Kratší stěny cihly tedy určíme následovně. Vybereme ty body, které leží

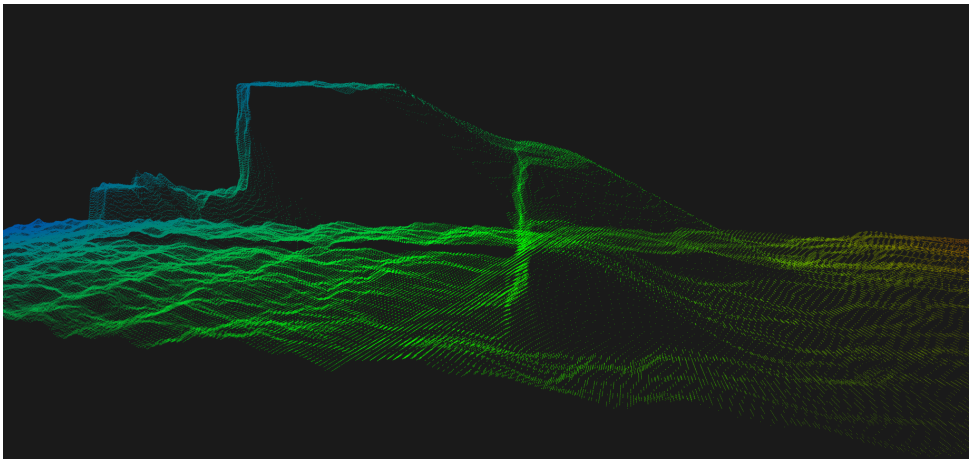

Obrázek 2.10: Výstup kamery - mračno bodů zobrazující skupinu cihel. V pravé části je vidět zkreslení hrany způsobující problém při segmentaci

mezi přímkami p_1 a p_2.Následně tyto body promítneme přímku p_1. Výpočet numericky zjednodušíme otočením bodů a přímek o θ, což je úhel sevřený přímkou p_1 a osou x. Projekcí na přímku p_1 se tedy stane vyčtení x-ové souřadnice každého bodu.

Následně je pro každý bod $\mathbf{x} \in p_1$ určen počet bodů promítnutých do okolí o velikosti ϵ. Jsou vybrány dva body s nejvyšší hodnotou, tyto jsou ilustrovány na obrázku 2.14 modrou barvou. Těmito body prochází přímky p_3 a p_4, které jsou kolmé na p_1, popřípadě p_2 a představují zbylé 2 stěny obdélníku. Rohy obdélníku r se pak určí jako průsečíky přímek p.

Nyní se z bodů představující obrys odečtou ty, které popisují obdélník r. Pokud počet zbývajících bodů obrysu je větší, než předem určený limit, pak se proces počínaje hledáním přímky opakuje.

Ve chvíli kdy jsou nelezeny všechny obdélníky, jsou tyto stejně jako v sekci 2.6.2 jeho rohy transformovány zpět do obrazu a celý postup se opakuje pro další shluky a vrstvy cihel.

2.7 Výsledky

Porovnání jednotlivých výsledků, přesnost + časová náročnost

2.8 Závěr

Zhodnocení vhodnosti IntelRealsense pro detekci a zhodnocení prezentovaných algoritmů

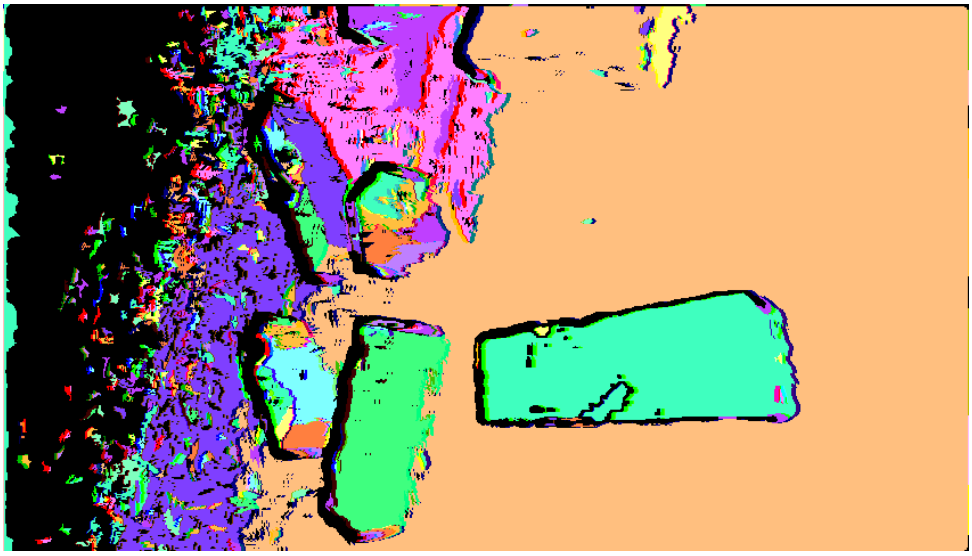

Obrázek 2.11: Výsledek segmentace obrazu podle velikosti derivace výšky.

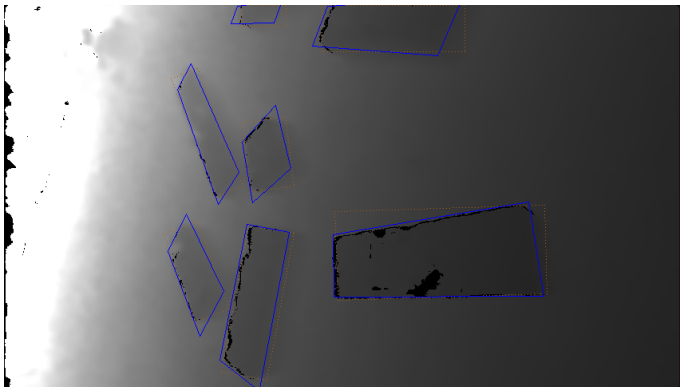

Obrázek 2.12: Příklad detekce cihel z hloubkových dat. Modře ohraničující obdélník po odstranění prespektivního zkreslení, hnědě ohraničující obdélník u kterého není bráno v potaz prespektivní zkreslení

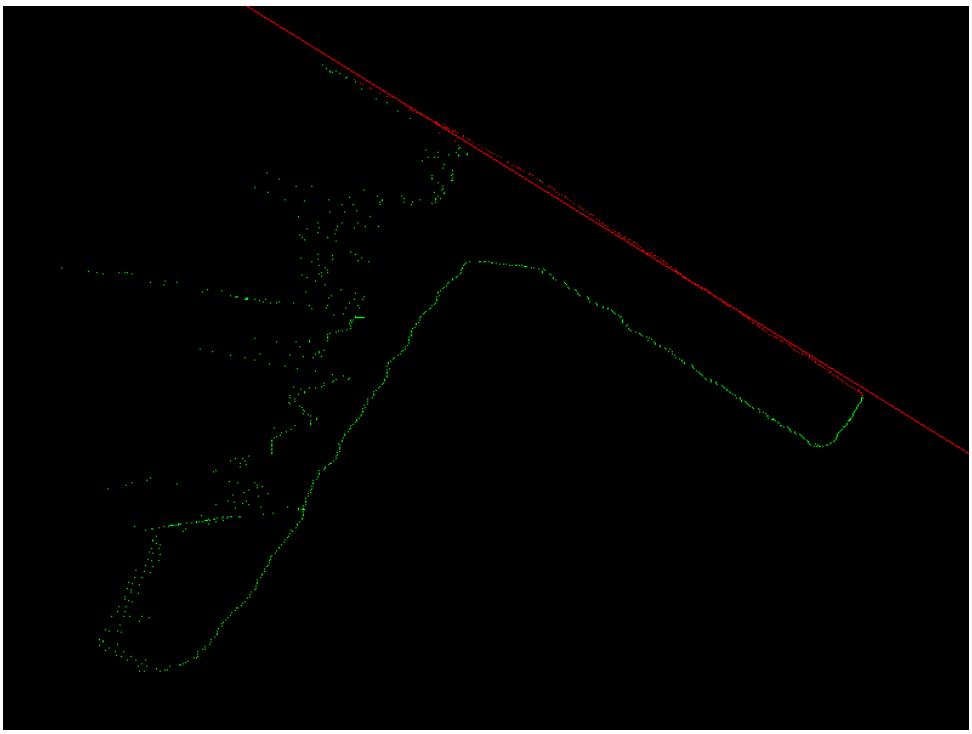

Obrázek 2.13: Detekce přímky pomocí RANSAC algoritmu

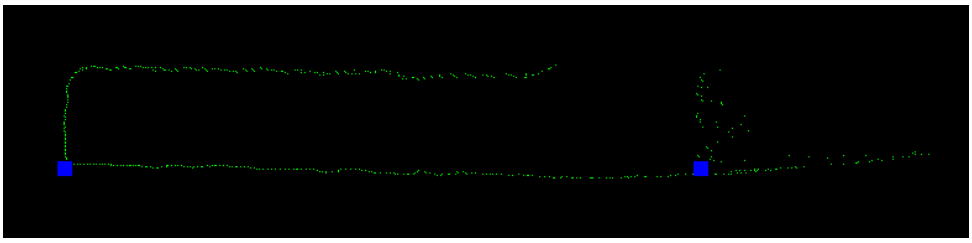

Obrázek 2.14: Detekce kratších hran cihly.

Literatura

[1] *The Intel® RealSense™ Depth Camera D435.*

[2] Stereo and 3d vision.

[3] *Intel® RealSense™ D400 Series Product Family*, 2019.

[4] Panagiotis-Alexandros Bokaris, Damien Muselet, and Alain Trémeau. 3D reconstruction of indoor scenes using a single RGB-D image. In *12th International Conference on Computer Vision Theory and Applications (VISAPP 2017)*, Porto, Portugal, February 2017.

[5] Myron Z Brown, Darius Burschka, and Gregory D Hager. Advances in computational stereo. *IEEE transactions on pattern analysis and machine intelligence*, 25(8):993–1008, 2003.

[6] R. V. Chadnov and A. V. Skvortsov. Convex hull algorithms review. In *Proceedings. The 8th Russian-Korean International Symposium on Science and Technology, 2004. KORUS 2004.*, volume 2, pages 112–115 vol. 2, 2004.

[7] Timothy M Chan. Optimal output-sensitive convex hull algorithms in two and three dimensions. *Discrete & Computational Geometry*, 16(4):361–368, 1996.

[8] Orazio Gallo, Roberto Manduchi, and Abbas Rafii. Cc-ransac: Fitting planes in the presence of multiple surfaces in range data. *Pattern Recognition Letters*, 32(3):403–410, 2011.

[9] Dirk Holz, Stefan Holzer, Radu Bogdan Rusu, and Sven Behnke. Real-time plane segmentation using rgb-d cameras. In *Robot Soccer World Cup*, pages 306–317. Springer, 2011.

[10] Walker James W. Angle Between Vectors, nov 2014.

[11] Dilpreet Kaur and Yadwinder Kaur. Various image segmentation techniques: a review. *International Journal of Computer Science and Mobile Computing*, 3(5):809–814, 2014.

[12] Leonid Keselman, John Iselin Woodfill, Anders Grunnet-Jepsen, and Achintya Bhowmik. Intel realsense stereoscopic depth cameras. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition Workshops*, pages 1–10, 2017.

[13] Annika Kuhl. Comparison of stereo matching algorithms for mobile robots. *The University of Western Australia Faculty of Engineering, Computing and Mathematics*, 2005.

[14] Kevin Lai, Liefeng Bo, Xiaofeng Ren, and Dieter Fox. A large-scale hierarchical multi-view rgb-d object dataset. In *2011 IEEE international conference on robotics and automation*, pages 1817–1824. IEEE, 2011.

[15] David Pichardie and Yves Bertot. Formalizing convex hull algorithms. In *International Conference on Theorem Proving in Higher Order Logics*, pages 346–361. Springer, 2001.

[16] Radu Bogdan Rusu, Nico Blodow, Zoltan Csaba Marton, and Michael Beetz. Close-range scene segmentation and reconstruction of 3d point cloud maps for mobile manipulation in domestic environments. In *2009 IEEE/RSJ International Conference on Intelligent Robots and Systems*, pages 1–6. IEEE, 2009.

[17] Satoshi Suzuki et al. Topological structural analysis of digitized binary images by border following. *Computer vision, graphics, and image processing*, 30(1):32–46, 1985.

[18] Godfried T Toussaint. Complexity, convexity, and unimodality. *International journal of computer & information sciences*, 13(3):197–217, 1984.

[19] Alexander JB Trevor, Suat Gedikli, Radu B Rusu, and Henrik I Christensen. Efficient organized point cloud segmentation with connected components. *Semantic Perception Mapping and Exploration (SPME)*, 2013.

[20] Jiefei Wang, Matthew Garratt, and Sreenatha Anavatti. Dominant plane detection using a rgb-d camera for autonomous navigation. In *2015 6th International Conference on Automation, Robotics and Applications (ICARA)*, pages 456–460. IEEE, 2015.

[21] Serge Weisstein Eric W., Belonie. Rodrigues' rotation formula. Visited on 8/04/20.

[22] Tomáš Werner. *Optimalizace*. České vysoké učení technické, 11.2.2020 edition, 2020.

[23] Lizhi Zhang, Diansheng Chen, and Weihui Liu. Fast plane segmentation with line primitives for rgb-d sensor. *International Journal of Advanced Robotic Systems*, 13(6):1729881416665846, 2016.